

8. gyakorlat tananyag

CYK algoritmus

Ha G egy tetszőleges környezetfüggetlen grammatika, ahol $u \in \Sigma^*$, eldönthető, hogy az u szó benne van-e a grammatika által generált nyelvben. Ilyenkor a Chomsky normálformájú grammatika algoritmikusan előállítható. Mondjuk azt, hogy $n = |u|$. $n = 0$ esetén azt mondhatjuk, hogy ha $u \in L(G)$, akkor ez ekvivalens azzal, hogy $S \rightarrow \epsilon \in P$. Teljes indukcióval látható, hogy $n \geq 1$ esetén a szó levezetése $n - 1$ darab $A \rightarrow BC$ és n darab $A \rightarrow a$ típusú szabály alkalmazásából áll. Emiatt el tudjuk dönteni, hogy a szó benne van-e a generált nyelvben.

Ha erről az oldalról nézzük, csak exponenciális felső becslést tudunk adni a szóprobléma eldöntésének hatékonyságára. u levezetésére viszont létezik egy hatékonyabb mód, amit dinamikus programozás segítségével érhetünk el, így az algoritmus már polinomiális hatékonyságú lesz. Az érdem Cocke, Younger és Kasami algoritmus, amit röviden CYK-ként is szoktunk emlegetni. Ezáltal a Chomsky-normálformában adott grammatika $|G| \cdot n^3$ nagyságrendű lépésben eldönti a szóproblémát.

A **Cocke-Younger-Kasami (CYK) algoritmus** során inputként egy környezetfüggetlen, Chomsky-normálformában levő $G = (N, \Sigma, P, S)$ grammatika és egy $u \in \Sigma^*$ szó adott. Outputként meghatározható, hogy a szó benne van-e a grammatika által generált nyelvben. Legyen ekkor $u = t_1 \dots t_n, t_i \in \Sigma, n \geq 1$. Tegyük fel, hogy A_i a $P_i \in P$ szabály bal-, β_i pedig a jobboldala úgy, hogy $1 \leq i \leq |P|, A_i \in N, \beta_i \in \Sigma \cup N^2$. Rekurzívan definiáljuk a $H_{i,j}, 1 \leq i \leq j \leq n$ halmazokat $j - i$ szerint növekvő sorrendben:

- $H_{i,j} = \{A_j | \beta_j = t_i\}$
- $H_{i,j} = \{A_k | \beta_k \in \bigcup_{h=i}^{j-1} H_{i,h} H_{h+1,j}\} (i < j)$

Ha $S \in H_{1,n}$ a szó benne van $L(G)$ -ben.

Az algoritmus legkönnyebben hat lépésre bontható.

- Legyen $G = (N, \Sigma, P, S)$ egy Chomsky normálformájú grammatika.
- Készíteni fogunk egy háromszög alakú táblázatot, amelyben a sorok a $a_1 \dots a_n$ szót reprezentálják.
- A táblázat $x_{i,j}$ eleme azon A nemterminálisokat tartalmazza, amelyekre az $A \Rightarrow^* a_i \dots a_j$ levezetés teljesül.
- Az első sorban, alulról felfelé x_{ii} minden olyan A nemterminálist tartalmaz, amelyre $A \rightarrow a_i \in P$ teljesül.

- A $(j - i + 1)$ -edik sorban lévő $x_{i,j}$ kiszámításához minden olyan A nemterminálist veszünk, amelyre $A \Rightarrow^* a_i \dots a_j$ teljesül. Ennek megfelelően minden olyan A nemterminálist tartalmazni fog, amelyre $A \rightarrow BC \in P$ fennáll, ahol $B \in x_{ik}$ és $C \in x_{k+1,j}$, ahol $i \leq k < j$.
- $u = a_1 \dots a_n \in L(G) \Leftrightarrow S \in x_{1n}$.

x_{14}			
x_{13}	x_{24}		
x_{12}	x_{23}	x_{34}	
x_{11}	x_{22}	x_{33}	x_{44}
a_1	a_2	a_3	a_4

Legyen $G = (N, \Sigma, P, S)$, ahol $N = \{S, A, B, X, Y, Z\}$, $\Sigma = \{a, b\}$, valamint

$P = \{S \rightarrow AY, Y \rightarrow XB, X \rightarrow BA, X \rightarrow ZA, Z \rightarrow BX, A \rightarrow a, B \rightarrow b\}$

. Döntsük el, hogy benne van-e a grammatika által generált nyelvben az **abbaab** szó!

A grammatika szabályhalmazát tekintve kijelenthetjük, hogy Chomsky-normálformában van, így ezzel nincs dolgunk.

Készítsünk egy 7 soros, 6 oszlopos táblázatot, melynek utolsó sorába, az $a_1 \dots a_6$ szimbólumok helyére az **abbaab** szót írjuk.

a	b	b	a	a	b

A következő, eggyel feljebbi sorba a cellákhoz azokat a nemterminálisokat írjuk, amelyekből az utolsó sor adott terminálisai közvetlenül elé

rhetők. Az $A \rightarrow a$ szabály miatt az a szimbólumok fölé A -t, a $B \rightarrow b$ szabály miatt a b szimbólumok fölé B -t írunk. (Ha több nemterminálisból is elérhető ugyanaz a terminális, akkor felírjuk őket halmazként.)

A	B	B	A	A	B
a	b	b	a	a	b

Vegyük az x_{12} cellát. Az értékét úgy kapjuk meg, hogy vennünk kell az összes olyan kapcsolatot, ahol $i \leq k < j$ és $A \rightarrow BC \in P$ fennáll úgy, hogy $B \in x_{ik}$ és $C \in x_{k+1,j}$. Ezért $x_{12} = x_{11}x_{22}$, amely értéke $x_{11}x_{22} = AB$. Mivel AB nem szerepel egy szabály jobboldalán sem, ebből a cellába $\emptyset$ -t írunk.

$x_{23} = x_{22}x_{33}$, vagyis $x_{22}x_{33} = BB$, ezért ide szintén $\emptyset$ -t írunk.

$x_{34} = x_{33}x_{44} = X$. Mivel létezik olyan szabály, amelynek a jobboldalán a BA megtalálható, $X \rightarrow BA \in P$, ezért az x_{34} -be az X kerül.

$x_{45} = x_{44}x_{55} = \emptyset$, AA miatt a cellába $\emptyset$ -t írunk.

$x_{56} = x_{55}x_{66} = \emptyset$, AB miatt a cellába $\emptyset$ -t írunk.

$\emptyset$	$\emptyset$	X	$\emptyset$	$\emptyset$	
A	B	B	A	A	B
a	b	b	a	a	b

Innentől kezdve háromszög alakban haladunk végig. Ahogy felfelé haladunk a sorban, eggyel több lehetőséget kell megvizsgálnunk. Vegyük most

az x_{13} cellát. Ekkor először nézzük meg az oszlopában lévő utolsó elemet és az x_{13} alatt átlósan helyet kapó értéket. Ebből következik $x_{13} = x_{11}x_{23}$. Azonban az algoritmus 5. pontjában leírtak szerint, meg kell vizsgálnunk még az $x_{13} = x_{12}x_{33}$ esetet is, ezért x_{13} értéke azon nemterminálisok halmaza lesz, amelyek ezekből a vizsgálatokból kikerülnek. $x_{13} = x_{11}x_{23} + x_{12}x_{33} = A\emptyset + \emptyset B = \emptyset$.

$x_{24} = x_{22}x_{34} + x_{23}x_{44} = BX + \emptyset A = Z$. Mivel létezik olyan szabály, amelynek a jobboldalán a BX szerepel, $Z \rightarrow BX \in P$, ezért a cellába a Z kerül.

$x_{35} = x_{33}x_{45} + x_{34}x_{55} = B\emptyset + XA = \emptyset$, XA nincs a jobboldalon.

$x_{46} = x_{44}x_{56} + x_{45}x_{66} = A\emptyset + \emptyset B = \emptyset$.

$\emptyset$	Z	$\emptyset$	$\emptyset$		
$\emptyset$	$\emptyset$	X	$\emptyset$	$\emptyset$	
A	B	B	A	A	B
a	b	b	a	a	b

$x_{14} = x_{11}x_{24} + x_{12}x_{34} + x_{13}x_{44} = AZ + \emptyset X + \emptyset A = \emptyset$.

$x_{25} = x_{22}x_{35} + x_{23}x_{45} + x_{24}x_{55} = B\emptyset + \emptyset\emptyset + ZA = X$, mivel $X \rightarrow ZA \in P$.

$x_{36} = x_{33}x_{46} + x_{34}x_{56} + x_{35}x_{66} = B\emptyset + X\emptyset + \emptyset B = \emptyset$.

$\emptyset$	X	$\emptyset$			
$\emptyset$	Z	$\emptyset$	$\emptyset$		
$\emptyset$	$\emptyset$	X	$\emptyset$	$\emptyset$	
A	B	B	A	A	B
a	b	b	a	a	b

$$x_{15} = x_{11}x_{25} + x_{12}x_{35} + x_{13}x_{45} + x_{14}x_{55} = AX + \emptyset\emptyset + \emptyset\emptyset + \emptyset A = \emptyset$$

$$x_{26} = x_{22}x_{36} + x_{23}x_{46} + x_{24}x_{56} + x_{25}x_{66} = B\emptyset + \emptyset\emptyset + Z\emptyset + XB = Y$$

, mivel $Y \rightarrow XB \in P$.

$\emptyset$	Y				
$\emptyset$	X	$\emptyset$			
$\emptyset$	Z	$\emptyset$	$\emptyset$		
$\emptyset$	$\emptyset$	X	$\emptyset$	$\emptyset$	
A	B	B	A	A	B
a	b	b	a	a	b

$$x_{16} = x_{11}x_{26} + x_{12}x_{36} + x_{13}x_{46} + x_{14}x_{56} + x_{15}x_{66} = AY + \emptyset\emptyset + \emptyset\emptyset + \emptyset$$

, mivel $S \rightarrow AY \in P$. Mivel az utolsó cellába az S kezdőszimbólum került, ezért az *abbaab* szó eleme a grammatika által generált nyelvnek, vagyis $abbaab \in L(G)$.

S					
$\emptyset$	Y				
$\emptyset$	X	$\emptyset$			
$\emptyset$	Z	$\emptyset$	$\emptyset$		
$\emptyset$	$\emptyset$	X	$\emptyset$	$\emptyset$	
A	B	B	A	A	B
a	b	b	a	a	b

Órai feladat 1:

Legyen $G = (N, \Sigma, P, S)$, $N = \{S, A, B, C, D\}$, $\Sigma = \{a, b, c\}$ és

$P = \{S \rightarrow AB, A \rightarrow CA, A \rightarrow SS, B \rightarrow CD, A \rightarrow b, D \rightarrow a, C \rightarrow c, C \rightarrow b\}$ egy Chomsky normálformájú grammatika. Döntsük el, hogy az *abcacb* és *bbcbbba* szavak benne vannak-e a grammatika által generált nyelvben!

Órai feladat 2:

Legyen $G = (N, \Sigma, P, S)$, $N = \{S, A, B, C, U, V, W, X, Y, Z\}$, $\Sigma = \{a, b, c\}$ és $P = \{S \rightarrow AB, S \rightarrow BC, A \rightarrow XA, A \rightarrow a, X \rightarrow a, C \rightarrow YC, C \rightarrow c, Y \rightarrow c, B \rightarrow UV, B \rightarrow VW, B \rightarrow XS, U \rightarrow a, V \rightarrow b, W \rightarrow c, X \rightarrow a, Y \rightarrow b, Z \rightarrow c\}$ egy Chomsky normálformájú grammatika. Döntsük el, hogy az **aabbcc** szó benne van-e a grammatika által generált nyelvben!

Bar-Hillel lemma (pumpáló lemma)

Minden L környezetfüggetlen nyelvhez meg tudunk adni két természetes számot, p -t és q -t úgy, hogy minden olyan szó L -ben, amely hosszabb, mint p , $uvxyz$ alakú, ahol $|vxy| \leq q$, $vy \neq \epsilon$, és minden $uv^i xy^i z$ szó is benne van az L nyelvben minden $i \geq 0$ egész számra ($u, v, x, y, z \in \Sigma^*$).

Mit jelent ez a gyakorlatban?

Legyen $L_1 = \{a^n b^m a^n \mid n \geq m\}$. Mondjuk azt, hogy bevezetjük a p természetes számot úgy, hogy $w = a^p b^p a^p \in L_1$, amely azért működik, mivel $n = m = p$ és $|w| \geq p$, ezért az $n \geq m$ teljesül.

A lemma szerint vegyünk egy $w = uvxyz$ szót, amelyre a $|vxy| \leq p$, $|vy| > 0$ relációk fennállnak. A $|vxy| \leq p$ azt jelöli, hogy a középső rész maximum egy blokkot fedhet le a 3-ból: $a^p \mid b^p \mid a^p$. Ezért vxy csak az alábbi helyeken lehet:

- 1. eset: v és y csak az első a blokk között van. $i = 2$ pumpálás esetén, mivel az elején több a lesz, de a vége nem változik, vagyis $a^{p+k} b^p a^p$ már nem lesz L_1 -ben, hiszen az első és utolsó a -s blokk mérete meg kell, hogy egyezzen.
- 2. eset: v és y csak a b -k között van. $i = 2$ pumpálás esetén, mivel több b lesz a belső blokkban, vagyis $a^p b^{p+k} a^p$ -t kapunk, azzal megsértjük a nyelvre vonatkozó szabályt, miszerint $n \geq m$, hiszen megadott számú pumpálás esetén eljuthatunk $m > n$ -ig.
- 3. eset: v és y az utolsó a blokk között van. Hasonló eset, mint az első.
- 4. eset: vxy átnyúlik az ab vagy ba határon. Pumpáláskor az a -k és b -k aránya elromlik, az első és utolsó a blokk mérete el fog térni. Mivel minden lehetséges felbontásnál van olyan i érték, amelyre $uv^i xy^i z \notin L_1$, ezért L_1 nem környezetfüggetlen.

Legyen $L_2 = \{ww \mid w \in \{a, b\}^*\}$. Tegyük fel indirekt módon, hogy a nyelv k

örnyezetfüggetlen. Ekkor vegyünk egy $w = a^p b^p a^p b^p$ szót, amelyet felírhatunk $w = (a^p b^p)(a^p b^p)$, amely eleme L_2 -nek. Bontsuk fel a szót úgy, hogy $w = uvxyz$, ahol $|vxy| \leq p, |vy| > 0$. Mivel $|vxy| \leq p$, ezért legfeljebb egy blokkba esik, vagy esetleg két szomszédos blokk határán lehet:

$a^p \mid b^p \mid a^p \mid b^p$.

- 1. eset: v és y egy blokkban van. Ha az első részszó a^p blokkjában van, és $i = 2$ -vel pumpálunk, akkor az első fél megváltozik, a második viszont nem, $(a^{p+k} b^p)(a^p b^p)$, amivel viszont a fő szóalak megváltozik.
- 2. eset: vxy két blokk határán van. Pumpáláskor az első fél torzul, a második fél változatlan marad, ergo, megint sérül a nyelv szóalakja.
- 3. eset: vxy középen van. A pumpálás során az egyik részszó vége, a másik részszó eleje az, ami módosulni kényszerül, vagyis megint nem lesz a két részszó azonos.

Mivel minden lehetséges felbontásnál van olyan i érték, amelyre $uv^i xy^i z \notin L_2$, ezért L_2 nem környezetfüggetlen.

Órai feladat 3:

Bizonyítsuk be, hogy az $L = \{w \mid w \in \{a, b, c\}^*, |w|_a = |w|_b = |w|_c\}$ nyelv nem környezetfüggetlen!

Órai feladat 4:

Bizonyítsuk be, hogy

- $L_1 = \{a^i b^{2i} c^j \mid i, j \geq 0\}$
- $L_2 = \{a^i b^i c^{2j} \mid i, j \geq 0\}$
- $L_3 = L_1 \cup L_2$ nyelvek nem környezetfüggetlenek!

Veremautomaták

Beszéltünk már egyszerű, véges automatákról. Veremautomata esetén a véges automatát általánosítjuk, potenciálisan végtelen vermet és véges kontrollt biztosítunk a szavak feldolgozásához. Alapértelmezetten nemdeterminisztikus.

A **veremautomata** egy $A = (Z, Q, \Sigma, \delta, z_0, q_0, F)$ rendezett hetes, amelyben

- Z a veremszimbólumok véges halmaza, más néven veremábécé.
- Q az állapotok véges halmaza.
- Σ az inputszimbólumok véges halmaza, vagyis inputábécé.

- $\delta : Z \times Q \times (\Sigma \cup \{\epsilon\}) \rightarrow \mathcal{P}_{véges}(Z^* \times Q)$ az átmeneti függvény, ahol $\mathcal{P}_{véges}(X)$ az X véges részhalmazainak halmazát jelöli.
- $z_0 \in Z$ a kezdeti veremszimbólum.
- $q_0 \in Q$ a kezdőállapot.
- $F \subseteq Q$ az elfogadó állapotok, vagyis végállapotok halmaza.

A verem tetején lévő szimbólum, az aktuális állapot és az inputszimbólum együttesen határozzák meg a következő átmenetet. Minden lépésben kiveszünk egyetlen egy elemet a verem tetejéről, és beteszünk helyette néhányat. Ha $\delta(z, q, \epsilon)$ nem üres, akkor ϵ -átmenet hajtható végre, amely lehetővé teszi, hogy a veremautomata anélkül változtassa meg az állapotát és/vagy a verem tartalmát, hogy az inputszalagról betűt olvasna be.

A veremautomata **konfigurációja** egy olyan zqw alakú szó, ahol $z \in Z^*$ a verem aktuális tartalma, $q \in Q$ az aktuális állapot és $w \in \Sigma^*$ az input még feldolgozatlan része. Az $A = (Z, Q, \Sigma, \delta, z_0, q_0, F)$ veremautomata $w \in \Sigma^*$ bemenethez tartozó **kezdőkonfigurációja** $z_0 q_0 w$.

Legyen $t \in \Sigma \cup \{\epsilon\}, q, r \in Q, z \in Z$. Ekkor a következő **veremműveletek** történhetnek meg:

- $zqt \rightarrow \epsilon r \in M_\delta$: a z elemet kivehetjük a veremből
- $zqt \rightarrow zr \in M_\delta$: a verem tartalma változatlan maradhat
- $zqt \rightarrow z' r \in M_\delta$: a z -t lecseréljük z' -re a verem tetején ($z' \in Z$)
- $zqt \rightarrow zz' r \in M_\delta$: z' -t a verem tetejére tehetjük, z -re ($z' \in Z$)
- $zqt \rightarrow zz' z'' r \in M_\delta$: $z' z''$ -t a verem tetejére tesszük

Általánosan azt mondhatjuk, hogy $zqt \rightarrow wr \in M_\delta$, másik átírással $(w, r) \in \delta(z, q, t)$, ahol $w \in \Sigma^*$ tetszőleges Z feletti szó. A w szó kerül a z helyére, és w utolsó betűje lesz a verem tetején.

Az A veremautomata az $\alpha \in Z^* Q Z^*$ konfigurációt **egy lépésben** a $\beta \in Z^* Q Z^*$ konfigurációra **redukálja**, jelölése $\alpha \Rightarrow_A \beta$, ha létezik olyan $z \in Z, q, p \in Q, a \in \Sigma \cup \epsilon, r, u \in Z^*$ és $w \in \Sigma^*$, hogy $(u, p) \in \delta(z, q, a)$, valamint az $\alpha = rzqaw$ és $\beta = rupw$ egyenlőségek teljesülnek.

A veremautomata esetén akkor beszélhetünk **(több lépéses) redukcióról**, ha az $\alpha \in Z^* Q Z^*$ konfigurációt a $\beta \in Z^* Q Z^*$ konfigurációra redukálja, jelölése $\alpha \Rightarrow_A^* \beta$, ha vagy $\alpha = \beta$ fennáll, vagy létezik olyan $\alpha_1 \dots \alpha_n$ szavakból álló véges sorozat, ahol $\alpha = \alpha_1, \beta = \alpha_n$ és $\alpha_i \Rightarrow \alpha_{i+1}$ átmenetekkel dolgozunk, úgy, hogy $1 \leq i \leq n - 1$.

A veremautomata által elfogadott nyelv az $L(A) = \{w \in \Sigma^* \mid z_0 q_w \Rightarrow_A^* up, \text{ ahol } u \in Z^*, p \in F\}$.

Bár alapértelmezetten nemdeterminisztikus veremautomatákról beszélünk, létezik determinisztikus is. Legyen $A = (Z, Q, \Sigma, \delta, z_0, q_0, F)$ egy veremautomata. Az A -t **determinisztikusnak** nevezzük, ha minden $(z, q, a) \in Z \times Q \times \Sigma$ esetén $|\delta(z, q, a)| + |\delta(z, q, \epsilon)| = 1$. Vagyis minden $q \in Q, z \in Z$ esetén a $\delta(z, q, a)$ pontosan egy elemet tartalmaz minden $a \in \Sigma$ inputszimbólumra és $\delta(z, q, \epsilon) = \emptyset$, vagy $\delta(z, q, \epsilon)$ pontosan egy elemet tartalmaz és $\delta(z, q, a) = \emptyset$ minden $a \in \Sigma$ inputszimbólumra.

Legyen $V = \{a, b, c\}$ egy ábécé és legyen $L = \{ab^n cb^n a | n \geq 1\}$. Konstruáljunk ehhez egy veremautomatát, amely felismeri a nyelvet!

A veremautomata első lépésben beolvas egy a betűt az inputszalagról, és kiveszi, majd visszateszi a kezdő veremszimbólumot, miközben q_0 állapotból q_1 állapotba vált.

Ezután a q_1 állapotban b betűt olvas az inputszalagról, hozzáadja a veremhez, majd marad a q_1 állapotban. Addig ismételjük ezt a lépést, amíg a c szimbólumhoz érünk.

A c szimbólum olvasásakor átmegy q_2 állapotba, és nem változtatja meg a verem tartalmát.

Ezután ismét csak b -ket olvasunk, végig a q_2 állapotban, minden lépésben kiveszünk egy b betűt a veremből.

A sikeres működés végére akkor érünk, ha pontosan annyi b -t olvasunk ebben a fázisban, ahány a veremben már korábban szerepelt. Ekkor utolsó lépésben az a betűt olvassa, és törli a z_0 veremszimbólumot. A veremautomata üres veremmel fogadja el a szót.

Az $A = (Z, Q, \Sigma, \delta, z_0, q_0, F)$, $Q = \{q_0, q_1, q_2\}$, $Z = \{z_0, b\}$, $F = \emptyset$ veremautomata állapot-átmenetei a következők:

$$\delta(z_0, q_0, a) = (z_0, q_1)$$

$$\delta(z_0, q_1, b) = (bz_0, q_1), \delta(b, q_1, b) = (bb, q_1), \delta(b, q_1, c) = (bb, q_2)$$

$$\delta(b, q_2, b) = (\epsilon, q_2), \delta(z_0, q_2, a) = (\epsilon, q_2)$$

Órai feladat 5:

Legyen $V = \{a, b, c\}$ egy ábécé és legyen $L = \{c^m a^n b^n | m \geq 0, n \geq 1\}$.

Konstruáljunk egy veremautomatát, amely felismeri az L nyelvet!

Órai feladat 6:

Legyen $V = \{a, b\}$ egy ábécé és legyen $L = \{a^n b^{n-1} | n \geq 1\}$. Konstruáljunk egy veremautomatát, amely felismeri az L nyelvet!